classificationmodel

April 18, 2024

1 PR8-2: Classificatiemodellen in Machine Learning.

Van Pjotr en Sennen

Hieronder is een voorbeeld uit het hoorcollege hoe we de classificatiemodellen in Machine Learning kunnen toepassen. We gaan een classificatiemodel maken met de Titanic dataset. Waar de volgende stappen in voorkomen:

Hier importeren we alle benodigde libraries en lezen we de data in.

```
[]: import pandas as pd
  import sqlite3
  from sklearn.model_selection import train_test_split, cross_val_score
  from sklearn.tree import DecisionTreeClassifier
  from sklearn import tree
  from sklearn import metrics
  import matplotlib.pyplot as plt
  import warnings
  warnings.filterwarnings("ignore")

# Laad de connectie met de database voor later.
  conn = sqlite3.connect('data/go_sales.sqlite')
```

Eerst gaan we alle data inlezen die nodig zijn voor deze opdracht.

```
[]: df = pd.read_csv('data/titanic.csv')
df
```

```
[]:
           pclass
                    survived
     0
                 1
                           1
                                                  Allen, Miss. Elisabeth Walton
     1
                 1
                           1
                                                 Allison, Master. Hudson Trevor
     2
                 1
                           0
                                                   Allison, Miss. Helen Loraine
     3
                 1
                           0
                                          Allison, Mr. Hudson Joshua Creighton
     4
                 1
                           0
                              Allison, Mrs. Hudson J C (Bessie Waldo Daniels)
                3
                           0
     1304
                                                           Zabour, Miss. Hileni
                 3
     1305
                           0
                                                          Zabour, Miss. Thamine
     1306
                3
                           0
                                                      Zakarian, Mr. Mapriededer
     1307
                3
                           0
                                                            Zakarian, Mr. Ortin
```

1308	3	0				Z	Zimmerman	, Mr. Leo		
	sex	age	sibsp	parch	ticket	fare	cabin	embarked	boat	\
0	female	29.0000	0	0	24160	211.3375	В5	S	2	
1	male	0.9167	1	2	113781	151.5500	C22 C26	S	11	
2	female	2.0000	1	2	113781	151.5500	C22 C26	S	NaN	
3	male	30.0000	1	2	113781	151.5500	C22 C26	S	NaN	
4	female	25.0000	1	2	113781	151.5500	C22 C26	S	NaN	
•••	•••		•••		•••		•••			
1304	female	14.5000	1	0	2665	14.4542	NaN	C	NaN	
1305	female	NaN	1	0	2665	14.4542	NaN	C	${\tt NaN}$	
1306	male	26.5000	0	0	2656	7.2250	NaN	C	NaN	
1307	male	27.0000	0	0	2670	7.2250	NaN	C	NaN	
1308	male	29.0000	0	0	315082	7.8750	NaN	S	NaN	
	body			h	ome.dest					
0	NaN				ouis, MO					
1	NaN	Montreal,	PQ / C	hesterv	ille, ON					
2	NaN	Montreal,	PQ / C	hesterv	ille, ON					
3	135.0	Montreal,								
4	NaN	Montreal,	PQ / C	hesterv	ille, ON					
•••	•••				•••					
1304	328.0				NaN					
1305	NaN				NaN					
1306	304.0				NaN					
1307	NaN				NaN					
1308	NaN				NaN					

[1309 rows x 14 columns]

Hierna pakken we de data die we echt nodig hebben voor dit experiment.

```
[]: df = df.loc[:, ['pclass', 'sex', 'age', 'survived']]
df
```

	pclass	sex	age	survived
0	1	female	29.0000	1
1	1	male	0.9167	1
2	1	female	2.0000	0
3	1	male	30.0000	0
4	1	female	25.0000	0
•••	•••			
1304	3	female	14.5000	0
1305	3	female	NaN	0
1306	3	male	26.5000	0
1307	3	male	27.0000	0
1308	3	male	29.0000	0
	1 2 3 4 1304 1305 1306 1307	0 1 1 1 1 2 1 3 1 4 1 1304 3 1305 3 1306 3 1307 3	0 1 female 1 1 male 2 1 female 3 1 male 4 1 female 1304 3 female 1305 3 female 1306 3 male 1307 3 male	0 1 female 29.0000 1 1 male 0.9167 2 1 female 2.0000 3 1 male 30.0000 4 1 female 25.0000 1304 3 female 14.5000 1305 3 female NaN 1306 3 male 26.5000 1307 3 male 27.0000

[1309 rows x 4 columns]

Met de data die we nodig hebben in hand gaan we nu beginnen aan het one-hot encoden van de data.

```
[]: df['pclass'] = df['pclass'].astype(str)
df.dtypes
```

[]: pclass object
sex object
age float64
survived int64
dtype: object

Hierna pakken we de dummie data die we dan gaan gebruiken voor het trainen van het model.

```
[]: dummies_dataframe = pd.get_dummies(df.loc[:, ['sex','pclass']])
dummies_dataframe
```

[]:	sex_female	sex_male	pclass_1	pclass_2	pclass_3
0	True	False	True	False	False
1	False	True	True	False	False
2	True	False	True	False	False
3	False	True	True	False	False
4	True	False	True	False	False
•••	•••	•••		•••	
1304	True	False	False	False	True
1305	True	False	False	False	True
1306	False	True	False	False	True
1307	False	True	False	False	True
1308	False	True	False	False	True

[1309 rows x 5 columns]

Nu moeten de de dummie data nog toevoegen aan de orginele dataframe. Dan droppen wij de sex kolom en dan pakken we de rest van de tabel mee.

```
[]:
           pclass_1
                      pclass_2 pclass_3
                                           sex_female
                                                        sex_male
                                                                       age
                                                                             survived
     0
                True
                         False
                                    False
                                                  True
                                                            False 29.0000
                                                                                     1
     1
                         False
                                                 False
                                                                    0.9167
                                                                                    1
                True
                                    False
                                                             True
     2
                True
                         False
                                    False
                                                                                    0
                                                  True
                                                            False
                                                                    2.0000
     3
                True
                         False
                                    False
                                                 False
                                                             True
                                                                   30.0000
                                                                                    0
     4
                True
                         False
                                    False
                                                  True
                                                           False
                                                                   25.0000
                                                                                    0
```

•••	•••	•••	•••	••• •••	•••	•••	
1304	False	False	True	True	False	14.5000	0
1305	False	False	True	True	False	NaN	0
1306	False	False	True	False	True	26.5000	0
1307	False	False	True	False	True	27.0000	0
1308	False	False	True	False	True	29.0000	0

[1309 rows x 7 columns]

Hier gaan we de data opsplitsen in een train en test set. Dus verticaal opsplitsen in x en y.

```
[]: x = df.drop('survived', axis=1)
y = df['survived']
x
```

[]:	pclass_1	pclass_2	pclass_3	sex_female	sex_male	age
0	True	False	False	True	False	29.0000
1	True	False	False	False	True	0.9167
2	True	False	False	True	False	2.0000
3	True	False	False	False	True	30.0000
4	True	False	False	True	False	25.0000
•••	•••	•••	•••		•••	
1304	False	False	True	True	False	14.5000
1305	False	False	True	True	False	NaN
1306	False	False	True	False	True	26.5000
1307	False	False	True	False	True	27.0000
1308	False	False	True	False	True	29.0000

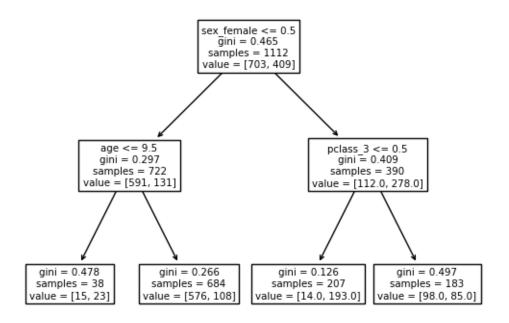
[1309 rows x 6 columns]

Nu gaan we de data splitsen in een train en test set. Dus horizontaal opsplitsen in x en y.

1.0.1 Met max_depth=2

Nu gaan we de decision tree classifier en daarna opbouwen en uiteindelijk evalueren.

```
[]: dtree = DecisionTreeClassifier(max_depth=2)
    dtree = dtree.fit(x_train, y_train)
    tree.plot_tree(dtree, feature_names=x.columns)
    plt.show()
```

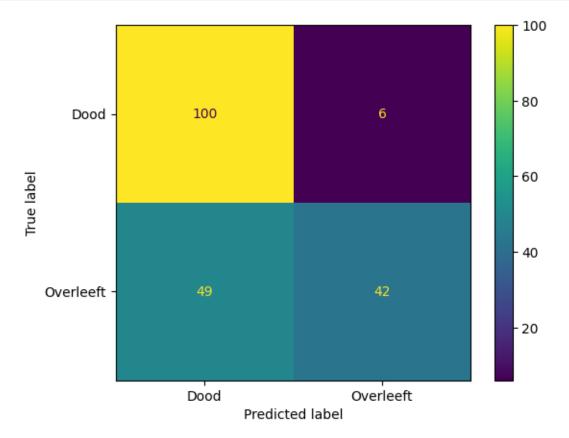


Daarna gaan we de data voorspellen en de confusion matrix maken.

```
predicted_df = pd.DataFrame(dtree.predict(x_test))
predicted_df = predicted_df.rename(columns={0: 'Predicted Survived'})
model_results_frame = pd.concat([y_test.reset_index()['survived'],__
predicted_df], axis=1)
model_results_frame
```

survived	Predicted Survived
0	0
1	0
0	0
0	0
0	0
•••	•••
0	0
1	0
0	0
0	0
0	0
	0 1 0 0 0 0 1

[197 rows x 2 columns]



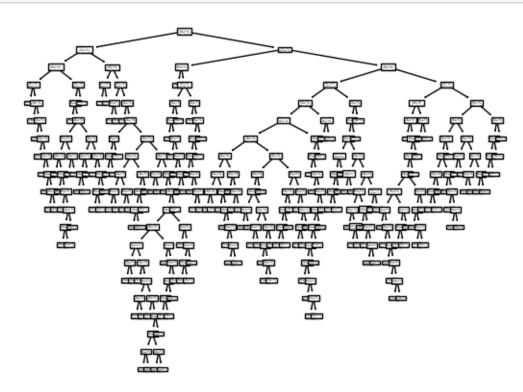
Nu moeten we nog de score berekenen van de classifier.

[]: 0.7208121827411168

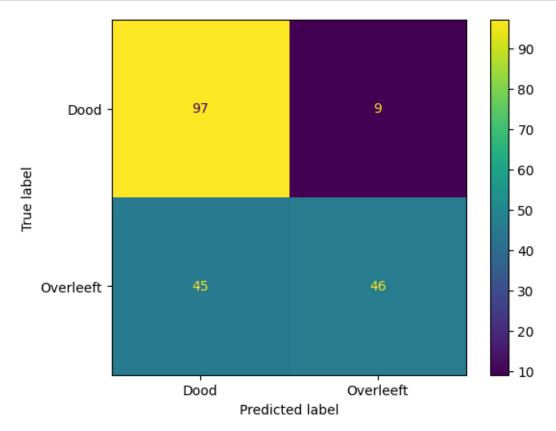
1.0.2 Geen max depth

Maar omdat we zojuist een decision tree classifier van een max depth van 2 hebben gemaakt, gaan we nu een classifier maken met geen max depth.

```
[]: dtree = DecisionTreeClassifier()
  dtree = dtree.fit(x_train, y_train)
  tree.plot_tree(dtree, feature_names=x.columns)
  plt.show()
```



_
U
0
0
0
0
0
0
0
0
0



```
[]: metrics.accuracy_score(model_results_frame['survived'], use of the control o
```

[]: 0.7258883248730964

2 Nu de echte opdracht

Great Outdoors wil graag weten wat de retourredenen gaan zijn op basis van een set onafhankelijke variabelen. Daarom wil zij een model trainen op basis van reeds bekende data, zodat deze volgend jaar in gebruik kan worden genomen. Let op: de retourreden kan ook "n.v.t." zijn, niet elke order

wordt namelijk geretourneerd; je zult dit moeten aanpakken door een join tussen "returned_item" en "order_details". Je doet dus het volgende met de reeds bekende data: - Bedenk met welke onafhankelijke variabelen dit naar verwachting het beste voorspeld kan worden en zet deze samen met de afhankelijke variabele in één DataFrame. - Pas waar nodig Dummy Encoding toe. - Snijd dit DataFrame horizontaal en verticaal op de juiste manier. - Train het classificatiemodel. - Evalueer de performance van je getrainde classificatiemodel a.d.h.v. een confusion matrix.

Dit is de opdracht die we gaan uitvoeren. In dit geval gaan we de retourreden voorspellen door gebruik te maken van producten type en de prijs van het product.

```
[]: order_details = pd.read_sql_query('SELECT * FROM order_details', conn)
returned_item = pd.read_sql_query('SELECT * FROM returned_item', conn)
returned_reason = pd.read_sql_query('SELECT * FROM return_reason', conn)
product = pd.read_sql_query("SELECT * FROM product", conn)
```

Tabellen gaan we nu mergen, hiervoor heb ik laatst een functie voor gemaakt om alle tabellen te mergen en kijken we alleen of de data wel van toepassing is in de tabel:

	111	rerea_	Jabie											
[]:		ORDER_	DETAI	L_CODE	ORDER	_NUMBEF	R PROD	UCT_NUM	BER	QUANTITY	UNIT	_COST	\	
	0			100250		9254	<u> </u>		43	52	1	26.51		
	1			100653		8483	3		113	36		6.01		
	2			100698		8495	5		7	20		46.38		
	3			100750		8498	3		18	40		86		
	4			100835		8492	2		40	56		17.97		
				•••		•••								
	701			98314		8206	3		77	86		45.31		
	702			98631		8239)		4	164		5		
	703			98653		8239)		6	22		85.11		
	704			98962		8239)		33	112		18		
	705			99188		8401	L		58	28		57.13		
		UNIT_F	PRICE	UNIT_S	ALE_PR	ICE TRI	AL879	RETURN	_CODE	2	RET	URN_DA	ГΕ	\
	0	18	39.77		189	.77	Т		2298	3 14-12-2	2021	11:28:	50	
	1	1	12.05		12	. 05	Т		2302	2 6-9-2	2021	17:43:	14	
	2		64		56	. 95	Т		1972	2 4-9-2	2022	03:07:4	48	
	3		129		11:	1.8	T		1978	3 23-8-2	2022	02:04:4	44	
	4		25		22	. 19	Т		1984	15-8-2	2022	13:33:	58	
			•••		•••			•••			•••			
	701	9	90.63		90	. 63	Т		1961	13-7-2	2021	17:43:4	43	
	702		7			7	T		1914	15-4-2	2022	13:32:3	28	

```
703
                                                          25-4-2022 22:56:33
           120
                             120
                                        Τ
                                                  1918
704
             27
                              27
                                        Τ
                                                  1932
                                                          10-4-2022 15:38:36
705
         79.98
                          71.98
                                        Τ
                                                  1944
                                                         26-10-2022 22:56:04
    RETURN_REASON_CODE RETURN_QUANTITY TRIAL888_x
                                                        RETURN_DESCRIPTION_EN
                                                            Defective product
0
                      1
                                        6
                                                   Τ
1
                      1
                                        4
                                                   Τ
                                                            Defective product
2
                      1
                                        2
                                                   Т
                                                            Defective product
                                        2
3
                      1
                                                   Τ
                                                            Defective product
4
                      1
                                        4
                                                   Τ
                                                            Defective product
. .
701
                      5
                                      86
                                                      Unsatisfactory product
702
                      5
                                     164
                                                   T Unsatisfactory product
                                                      Unsatisfactory product
703
                      5
                                      22
704
                      5
                                     112
                                                      Unsatisfactory product
                                                   T
                                                      Unsatisfactory product
705
                      5
                                      28
    TRIAL888_y
```

0 Τ Τ 1 2 Τ 3 Τ 4 Т 701 Τ 702 Τ 703 Τ 704 Τ 705 Т

[706 rows x 15 columns]

Hiernaa gaan we wat data eruit halen naast de Not A Number values. Met daarbij droppen we ook de date want die is niet van toepassing.

Daarnaast moeten we ook de TRAIL kolomen verwijderen, omdat deze niet van toepassing zijn.

['TRIAL879', 'TRIAL888_x', 'TRIAL888_y']

```
[]: selected_columns = filtered_table selected_columns
```

[]:		ORDER_DETAIL	L_CODE	ORDER_NUM	1BER	PRODUCT	_NUMBER	QUANTIT	Y U	NIT_COST	\		
	0	1	100250	Ş	9254		43	5	2	126.51			
	1	1	100653	8	3483		113	3	6	6.01			
	2	1	100698	8	3495		7	2	0	46.38			
	3	1	100750	8	3498		18	4	0	86			
	4	1	100835	8	3492		40	5	6	17.97			
			•••	•••			••	•••					
	701		98314	8	3206		77	8	6	45.31			
	702		98631	8	3239		4	16	4	5			
	703		98653	8	3239		6	2	2	85.11			
	704		98962	8	3239		33	11	2	18			
	705		99188	8	3401		58	2	8	57.13			
		UNIT_PRICE U	JNIT_SA	ALE_PRICE	RETU	JRN_CODE	RETURN	_REASON_C	ODE	RETURN_Q	UANT	ITY	\
	0	189.77		189.77		2298			1			6	
	1	12.05		12.05		2302			1			4	
	2	64		56.95		1972			1			2	
	3	129		111.8		1978			1			2	
	4	25		22.19		1984			1			4	
		•••		•••				•••		•••			
	701	90.63		90.63		1961			5			86	
	702	7		7		1914			5			164	
	703	120		120		1918			5			22	
	704	27		27		1932			5			112	
	705	79.98		71.98		1944			5			28	

RETURN_DESCRIPTION_EN

0	Defective	product
1	Defective	product
2	Defective	product
3	Defective	product
4	Defective	${\tt product}$

701 Unsatisfactory product

[706 rows x 11 columns]

Hier kijken we naar welke kolommen we nodig hebben voor de voorspelling. De return_description is waarschijnlijk de kolom die we nodig hebben. Aangezien die maar een waarde heeft van 5.s

```
[]: # We moeten controleren of er kolommen zijn die categorische variabelen⊔
⇒bevatten die moeten worden omgezet naar dummyvariabelen.

# Laten we eerst controleren welke kolommen categorisch zijn en hoeveel unieke⊔
⇒waarden ze bevatten.
```

⁷⁰² Unsatisfactory product

⁷⁰³ Unsatisfactory product

⁷⁰⁴ Unsatisfactory product

⁷⁰⁵ Unsatisfactory product

```
for column in selected_columns.columns:
         if selected_columns[column].dtype == 'object':
             print(f"{column}: {selected_columns[column].nunique()} unieke waarden")
     # In dit qeval is de kolom RETURN_DESCRIPTION_EN categorisch.
     # We passen Dummy Encoding toe op deze kolom.
     dummies_dataframe = pd.get_dummies(selected_columns.loc[:,__
     df = pd.concat([selected_columns, dummies_dataframe], axis=1)
     df
    ORDER_DETAIL_CODE: 706 unieke waarden
    ORDER NUMBER: 628 unieke waarden
    PRODUCT NUMBER: 112 unieke waarden
    UNIT COST: 231 unieke waarden
    UNIT PRICE: 232 unieke waarden
    UNIT SALE PRICE: 423 unieke waarden
    RETURN_CODE: 706 unieke waarden
    RETURN_REASON_CODE: 5 unieke waarden
    RETURN_QUANTITY: 66 unieke waarden
    RETURN_DESCRIPTION_EN: 5 unieke waarden
[]:
         ORDER_DETAIL_CODE ORDER_NUMBER PRODUCT_NUMBER QUANTITY UNIT_COST \
     0
                    100250
                                   9254
                                                     43
                                                               52
                                                                     126.51
     1
                    100653
                                   8483
                                                    113
                                                               36
                                                                       6.01
     2
                                   8495
                                                      7
                                                               20
                                                                      46.38
                    100698
     3
                                   8498
                                                     18
                                                               40
                    100750
                                                                         86
     4
                    100835
                                   8492
                                                     40
                                                               56
                                                                      17.97
     . .
    701
                                                     77
                                                               86
                                                                      45.31
                     98314
                                   8206
     702
                     98631
                                   8239
                                                      4
                                                              164
                                                                          5
     703
                     98653
                                   8239
                                                      6
                                                               22
                                                                      85.11
     704
                     98962
                                   8239
                                                     33
                                                              112
                                                                          18
     705
                                   8401
                                                               28
                     99188
                                                     58
                                                                      57.13
         UNIT PRICE UNIT SALE PRICE RETURN CODE RETURN REASON CODE RETURN QUANTITY
     0
             189.77
                             189.77
                                            2298
                                                                  1
                                                                                   6
     1
              12.05
                              12.05
                                            2302
                                                                  1
                                                                                   4
                                                                                   2
     2
                 64
                              56.95
                                            1972
                                                                  1
     3
                129
                                                                                   2
                              111.8
                                            1978
                                                                  1
     4
                 25
                              22.19
                                            1984
                                                                  1
                                                                                   4
                                                                  5
     701
              90.63
                              90.63
                                            1961
                                                                                  86
     702
                  7
                                  7
                                                                  5
                                                                                 164
                                            1914
                                                                  5
     703
                                                                                  22
                120
                                120
                                            1918
```

```
705
                          71.98
                                       1944
                                                              5
         79.98
      RETURN_DESCRIPTION_EN
                             RETURN_DESCRIPTION_EN_Defective product
0
          Defective product
1
          Defective product
                                                                  True
2
          Defective product
                                                                  True
3
          Defective product
                                                                  True
4
          Defective product
                                                                  True
701
    Unsatisfactory product
                                                                 False
702 Unsatisfactory product
                                                                 False
703 Unsatisfactory product
                                                                 False
704 Unsatisfactory product
                                                                 False
705 Unsatisfactory product
                                                                 False
     RETURN_DESCRIPTION_EN_Incomplete product
0
                                         False
1
                                         False
2
                                         False
3
                                         False
4
                                         False
701
                                         False
702
                                         False
703
                                         False
704
                                         False
705
                                         False
     RETURN_DESCRIPTION_EN_Unsatisfactory product \
0
                                             False
1
                                             False
2
                                             False
3
                                             False
4
                                              False
                                                •••
701
                                               True
702
                                              True
703
                                               True
704
                                               True
705
                                               True
     RETURN_DESCRIPTION_EN_Wrong product ordered \
0
                                             False
1
                                             False
2
                                             False
3
                                             False
4
                                             False
```

28

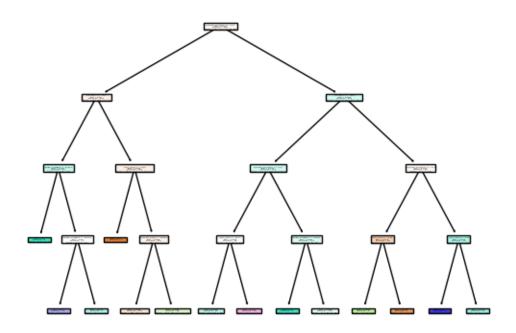
```
701
                                                 False
     702
                                                 False
     703
                                                 False
     704
                                                 False
     705
                                                 False
          RETURN_DESCRIPTION_EN_Wrong product shipped
     0
                                                 False
     1
                                                 False
     2
                                                 False
     3
                                                 False
     4
                                                 False
     701
                                                 False
     702
                                                 False
     703
                                                 False
     704
                                                 False
     705
                                                 False
     [706 rows x 16 columns]
[]: x = df.drop(columns=["RETURN_REASON_CODE", "RETURN_DESCRIPTION_EN", |
      →"RETURN_DESCRIPTION_EN_Defective product", "RETURN_DESCRIPTION_EN_Incomplete_
      →product", "RETURN_DESCRIPTION_EN_Unsatisfactory product",□
      → "RETURN DESCRIPTION EN_Wrong product ordered", "RETURN DESCRIPTION EN_Wrong
      →product shipped"]) # Onafhankelijke variabelen
     y = df[["RETURN DESCRIPTION EN"]] # Afhankelijke variabele
     x_train, x_test, y_train, y_test = train_test_split(x, y, test_size=0.15,_
      →random state=42)
     У
```

```
[]:
           RETURN DESCRIPTION EN
               Defective product
     0
               Defective product
     1
     2
               Defective product
     3
               Defective product
     4
               Defective product
     . .
     701 Unsatisfactory product
     702 Unsatisfactory product
     703 Unsatisfactory product
     704 Unsatisfactory product
     705 Unsatisfactory product
     [706 rows x 1 columns]
```

Nu zetten we alles in een Decision Tree Classifier en gaan we de data trainen.

```
[]: dtree = DecisionTreeClassifier(max_depth=4, random_state=1)
    dtree.fit(x_train, y_train)
    tree.plot_tree(dtree, feature_names=x.columns, filled=True)
    plt.show()
    scores = cross_val_score(dtree, x_train, y_train, cv=5)

print("Gemiddelde kruisvalidatiescore:", scores.mean())
    print("Standaarddeviatie van kruisvalidatiescores:", scores.std())
```



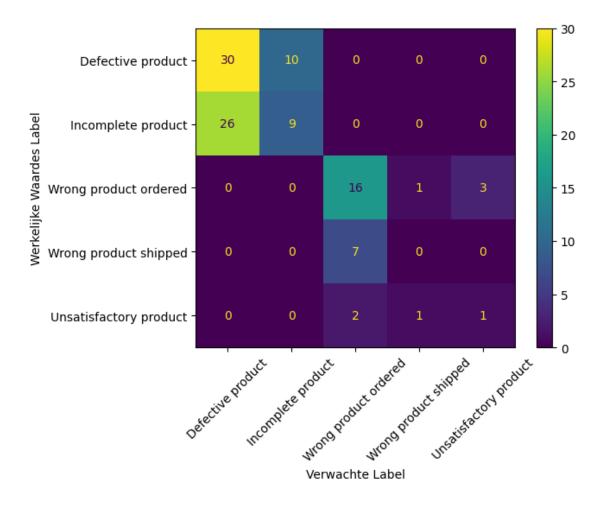
Nu gaan we voorspellingen maken en dan kijken of de data een goede score heeft. Score is 0.96, dus dat is een goede score.

Dit is de nauwkeurigheid van het model: 0.5283018867924528

```
[]:
          RETURN_DESCRIPTION_EN Predicted Return Reason
          Wrong product ordered Unsatisfactory product
     1
              Defective product
                                      Incomplete product
     2
              Defective product
                                      Defective product
     3
              Defective product
                                      Defective product
     4
             Incomplete product
                                      Defective product
                                      Defective product
             Incomplete product
     101
     102
              Defective product
                                      Defective product
              Defective product
     103
                                      Defective product
         Wrong product ordered Unsatisfactory product
     104
     105
              Defective product
                                      Defective product
```

[106 rows x 2 columns]

Nu gaan we de data in een confusion matrix zetten, waar we de prediction en de actual values in gaan zetten.



Nog een keer gaan we de data scoren, die zojuist in de confusion matrix is gezet. Dan gaan we kijken naar accuracy, sensitivity en specificity.

Dit is de accuracy van het model: 0.5283018867924528 Dit is de sensitivity van het model: 0.5283018867924528 Dit is de specificity van het model: 0.4887501773301178